

UNIVERSIDADE FEDERAL DE MINAS GERAIS

FACULDADE DE CIÊNCIAS ECONÔMICAS

TRABALHO DE ECONOMETRIA II

**Energia Elétrica Consumida na Região Sudeste -
Residencial**

Grupo J

Douglas Edson Silva de Oliveira


Parte 1

A série histórica escolhida foi sobre o uso de energia elétrica na região sudeste, focando exclusivamente no uso pelas residências.

O Gráfico 1 mostra a série histórica. A grande crise socioeconômica e política que dominou o Brasil fez com que houvesse uma mudança brusca de consumo de energia pelas famílias do sudeste. Nesse período, foram instituídas as bandeiras tarifárias, houve uma grande crise hídrica e o Governo deixou de segurar artificialmente o preço da energia. Desse modo, decidi utilizar os dados após de janeiro de 2017, visto a grande mudança de perfil de consumo.


No Gráfico 2, podemos notar a sazonalidade decorrente das estações do ano e das bandeiras tarifárias, bem como uma clara tendência que pode ser explicada, principalmente, pelas tendências demográficas e pela expansão da adoção de eletrodomésticos. Desse modo, a tendência faz com que a média da série para cada t não seja constante.

Gráfico 1: Consumo de Energia Elétrica nas Residências da Região Sudeste (Milhões de MWh) – Série Histórica Completa. (Jan/2004 – Feb/2026).




Fonte: Empresa de Pesquisa Energética

Gráfico 2: Consumo de Energia Elétrica nas Residências da Região Sudeste (Milhões de MWh) – Série Histórica Recortada (Jan/2017 – Feb/2026).



Fonte: Empresa de Pesquisa Energética


Gráfico 3: Decomposição pelo método aditivo.
Decomposition of additive time series



O Gráfico 3, obtido através da decomposição pelo método aditivo, mostra o que, em parte, já foi comentado acima. A tendência é nitidamente ascendente. E a sazonalidade reflete as

estações do ano, e, conseqüentemente, as bandeiras tarifárias que dependem diretamente dos ciclos hidrológicos . Já o erro aparenta ser bem comportado, circulando em torno de 0.

Gráfico 4: FAC e FACP



O Gráfico 4 demonstra os resultados da Função de Autocorrelação (FAC) e Função de Autocorrelação Parcial (FACP). Visualmente, devido ao lento e declinante caimento da FAC, percebe-se que o valor atual tem correlação com o valor em $t-1$, além de ter fortes indicadores de sazonalidade, como é notado no Lag 1 e Lag 2.

Já a FACP, o primeiro Lag quase toca no 1, e em seguida sofre um brusco decaimento para dentro da zona de insignificância, indicando que a série precisa ser diferenciada.

Os testes Dick-Fuller Aumentado e Phillips-Perron foram feitos para testar a hipótese nula de não-estacionariedade. Como pode ser notado na Imagem 1, a hipótese foi rejeitada em ambos testes, provavelmente se tratando de uma série estacionária em torno de uma tendência (trend-stationary). Mesmo com o diagnóstico, preferi fazer uma diferenciação.

Imagem 1: Teste Dickey-Fuller Aumentado e Phillips-Perron

```
> teste_pp <- PP.test(dados_pos_crise)
>
> print(teste_adf)

    Augmented Dickey-Fuller Test

data:  dados_pos_crise
Dickey-Fuller = -5.9569, Lag order = 4, p-value = 0.01
alternative hypothesis: stationary


> print(teste_pp)

    Phillips-Perron Unit Root Test

data:  dados_pos_crise
Dickey-Fuller = -4.9121, Truncation lag parameter = 4, p-value = 0.01
```

O Gráfico 5 mostra o resultado da FACP E FAC feito após tirar a primeira diferença comum e sazonal da série, removendo a longa memória e sazonalidade que era contida na série em nível.

Gráfico 5: FAC e FACP pós primeira diferença comum e sazonal.



Haja vista os resultados obtidos das primeiras diferenças, como mostra o Gráfico 5, foi observado que pós uma diferenciação comum e sazonal, os valores passam a depender pouco dos valores passados. Além disso, como visto, os choques podem influenciar o consumo atual. Para a diferenciação feita na sazonalidade, a interpretação é a mesma: após a diferenciação, observada no Gráfico 5, a sazonalidade se torna menos explicativa e os erros/choques anteriores podem explicar os choques atuais.

Os modelos candidatos seguem na linha do exposto acima.

Imagem 2: Modelos Candidatos

```

129 ##### Testes BIC E AIC
130
131
132 mod1 <- Arima(dados_pos_crise, order=c(0,1,1), seasonal=c(0,1,1))
133
134 mod2 <- Arima(dados_pos_crise, order=c(1,1,0), seasonal=c(1,1,0))
135
136 mod3 <- Arima(dados_pos_crise, order=c(1,1,1), seasonal=c(0,1,1))
137

```

O mod1 com (0,1,1)(0,1,1) indica o que foi falado acima, propõe médias móveis, assumindo que as variações no consumo sejam alteradas conforme os choques aleatórios.

O mod2 adiciona uma diferenciação sazonal e comum e inclui um fator AR(1), cogitando que o valor e sazonalidade em t dependa de um valor em t-j.

E o último, o mod3 propõe uma mistura entre os dois, uma junção entre AR e MA.


Como visto na Imagem 3, o modelo destaque e que passou nos Critérios de Informação AIC E BIC foi o mod1, escolha também amparada pelo princípio da parcimônia, destacado pela metodologia Box-Jenkins.

Imagem 3: Critérios de Informação

```
> AIC(mod1,mod2,mod3)
      df      AIC
mod1   3 13.09617
mod2   3 37.35975
mod3   4 14.18985
>
> BIC(mod1,mod2,mod3)
      df      BIC
mod1   3 20.82030
mod2   3 45.08388
mod3   4 24.48869
```

Como notado no Gráfico 6, a estabilidade do modelo foi confirmada pelo gráfico de raízes inversas do polinômio de médias móveis. Como todas as raízes se encontram estritamente dentro do círculo unitário, o modelo satisfaz a condição de invertibilidade. Isso garante que o impacto de choques passados decai ao longo do tempo, tornando as previsões para 2026 estatisticamente confiáveis.

Gráfico 6: Teste de Estabilidade



Como demonstrado no Gráfico 7 e Imagem 4, aplicou-se o teste de Ljung-Box. O resultado 0,18 indica que não podemos rejeitar a hipótese nula de ausência de autocorrelação serial. Portanto, o modelo capturou toda a estrutura sistemática dos dados, restando apenas ruído branco.

Imagem 4: Teste de Autocorrelação

```
Ljung-Box test

data: Residuals from ARIMA(0,1,1)(0,1,1)[12]
Q* = 25.34, df = 20, p-value = 0.1887

Model df: 2. Total lags used: 22
```

Gráfico 7: Teste de Autocorrelação





Imagem 5: Teste de Normalidade

```
Shapiro-wilk normality test

data: residuals(mod1)
W = 0.98518, p-value = 0.265
```

A normalidade dos resíduos foi verificada pelo teste Shapiro-Wilk, rejeitando a hipótese nula de não normalidade, como visto na Imagem 5 e Gráfico 8. Ademais, é possível também notar a distribuição em forma de sino no Gráfico 7.

Gráfico 8: Teste de Normalidade nos resíduos.



A análise da variância dos resíduos ao quadrado, no Gráfico 8 sugere que a série é homocedástica na maior parte do período. Apesar de alguns picos isolados, não se observa um padrão de 'agrupamento de volatilidade' (efeitos ARCH), indicando que a incerteza do modelo é estável para o horizonte de previsão.

Gráfico 8: Teste de homocedasticidade nos resíduos.





Gráfico 9 – Validação ex-post para o ano de 2025.



Para a previsão, decidi fazer uma análise de checagem ex-post para o ano de 2025, como é demonstrado no Gráfico 9. Confrontei os valores previstos (linha azul) com os dados

efetivamente realizados (linha vermelha) para o período de 2025 e início de 2026. O modelo consegue capturar as tendências e sazonalidades do consumo. Ademais, boa parte da série se situa dentro do intervalo de 80% de confiança.

Tabela 1: Valores Previstos e Valores Reais

	Mes_Ano	Real	Previsto	Erro_Abs	Erro_Pct
1	jan/25	7.22	6.69	0.53	7.30
2	fev/25	7.29	6.71	0.58	7.96
3	mar/25	7.60	7.11	0.49	6.40
4	abr/25	6.64	6.60	0.04	0.56
5	mai/25	6.51	6.58	-0.07	1.02
6	jun/25	6.12	6.20	-0.08	1.34
7	jul/25	6.38	5.95	0.43	6.80
8	ago/25	6.21	6.06	0.16	2.50
9	set/25	6.36	6.31	0.04	0.64
10	out/25	6.69	6.82	-0.13	1.97
11	nov/25	6.53	6.61	-0.08	1.16
12	dez/25	7.12	6.90	0.22	3.11
13	jan/26	7.81	6.78	1.04	13.27
14	fev/26	7.10	6.74	0.36	5.10

A análise da acurácia (Imagem 6) demonstra a performance do modelo selecionado. O MAPE (Erro Percentual Médio Absoluto) situou-se em 2,53% para a base de treino e 4,22% para a base de teste, valores que atestam a precisão das projeções para o consumo residencial. A métrica U de Theil (0,88), sendo inferior à unidade, ratifica que a especificação SARIMA proposta apresenta um ganho preditivo superior a modelos de passeio aleatório.

Imagem 6: Testes de Acurácia

```
> accuracy(mod1)
```

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	0.01200204	0.2084151	0.1578894	0.09796368	2.539773	0.546419	0.05183109

```
> acuracia_teste <- accuracy(previsao_expost, real_2025)
```

```
> print(acuracia_teste)
```

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	0.0001612072	0.2509243	0.1920260	-0.05270177	3.162399	0.6446105	-0.09654247	NA
Test set	0.2518560082	0.4102476	0.3026928	3.44018052	4.224260	1.0161072	0.34929741	0.8813013

E, por fim, no Gráfico 10, demonstro como ficou a previsão para 2026 e 2027 utilizando o mod1 utilizado acima.

Gráfico 10: Previsão para 2026 e 2027




Tabela 2: Tabela de Valores Previstos 2026/2027

	Mes_Ano	Previsao_Media	Limite_Inferior_95	Limite_Superior_95
1	mar/26	7.50	7.04	7.95
2	abr/26	7.10	6.61	7.58
3	mai/26	6.83	6.32	7.34
4	jun/26	6.59	6.06	7.13
5	jul/26	6.54	5.98	7.09
6	ago/26	6.56	5.98	7.14
7	set/26	6.80	6.20	7.40
8	out/26	7.03	6.41	7.65
9	nov/26	7.05	6.41	7.69
10	dez/26	7.28	6.62	7.94
11	jan/27	7.54	6.86	8.22
12	fev/27	7.38	6.68	8.08

Imagem 7: Acurácia para modelo Ex-Ante

```
> accuracy(mod_final)
      ME      RMSE      MAE      MPE      MAPE      MASE
Training set 0.01200204 0.2084151 0.1578894 0.09796368 2.539773 0.546419
      ACF1
Training set 0.05183109
> |
```

Anexo: R script

```
library(openxlsx)
```

```
library(tseries)
```

```
library(ggplot2)
```

```
library(zoo)
```

```
library(forecast)
```

```
options(scipen = 999)
```

```
datos <- read.xlsx('datosserie.xlsx')
```

```
datos$Data = my(datos$Data)
```

```
datos <- datos %>%
```

```
  arrange(Data)
```

```
datos <- ts(datos$Valor,  
            start = c(2004, 1),  
            frequency = 12)
```

```
datos_pos_crise <- window(datos,start = c(2017,1))
```

```
##### Grafico
```

```
df_plot <- data.frame(  
  Data = as.Date(datos),  
  Valor = as.numeric(datos)
```

```
)
```

```
ggplot(df_plot, aes(x = Data, y = Valor)) +
```

```
  geom_line(color = "steelblue", linewidth = 1) + # No ggplot2 atual, use 'linewidth' em vez de  
  'size'
```

```
  geom_abline(intercept = 0, slope = 1, color = "red", linetype = "dashed") +
```

```
  labs(x = "Ano",
```

```
        y = "Consumo de Energia Elétrica na Rede (Milhões de MWh)",
```

```
        caption = "Fonte: Empresa de Pesquisa Energética ") +
```

```
  theme_light() +
```

```
  scale_x_date(date_labels = "%Y", date_breaks = "5 years")
```

```
ggsave("graficotodo.png", width = 20, height = 15, units = "cm", dpi = 300)
```

```
df_pos <- data.frame(
```

```
  Data = as.Date(dados_pos_crise),
```

```
  Valor = as.numeric(dados_pos_crise)
```

```
)
```

```
ggplot(df_pos, aes(x = Data, y = Valor)) +
```

```
  geom_line(color = "steelblue", linewidth = 1) + # No ggplot2 atual, use 'linewidth' em vez de  
  'size'
```

```
  geom_abline(intercept = 0, slope = 1, color = "red", linetype = "dashed") +
```

```
  labs(x = "Ano",
```

```

y = "Consumo de Energia Elétrica na Rede (Milhões de MWh)",
caption = "Fonte: Empresa de Pesquisa Energética ") +
theme_light() +
scale_x_date(date_labels = "%Y", date_breaks = "5 years")
ggsave("graficoposcrise.png", width = 20, height = 15, units = "cm", dpi = 300)
ggsave("grafico134.png", width = 20, height = 15, units = "cm", dpi = 300)

##### FAC e FACP

par(mfrow = c(1, 2))

acf(dados_pos_crise, main = "FAC", lag.max = 24)

pacf(dados_pos_crise, main = "FACP", lag.max = 24)

##### Decomposicao
dec <- decompose(dados_pos_crise, type = "additive")

autoplot(dec) +
  labs(x = "Tempo",
       y = "Valor") +
  theme_minimal()

##### Teste DFA e PP

teste_adf <- adf.test(dados_pos_crise)
teste_pp <- PP.test(dados_pos_crise)

print(teste_adf)
print(teste_pp)

##### Diferenciação e FACP, FAC, PP e ADF

```

```
série_diferenciada <- diff(diff(dados_pos_crise),lag = 12)
```

```
par(mfrow = c(1, 2))
```

```
acf(série_diferenciada, main = "FAC", lag.max = 24)
```

```
pacf(série_diferenciada, main = "FACP", lag.max = 24)
```

```
teste_adfDIFF <- adf.test(série_diferenciada)
```

```
teste_ppDIFF <- PP.test(série_diferenciada)
```

```
print(teste_adfDIFF)
```

```
print(teste_ppDIFF)
```

```
##### Testes BIC E AIC
```

```
mod1 <- Arima(dados_pos_crise, order=c(0,1,1), seasonal=c(0,1,1))
```

```
mod2 <- Arima(dados_pos_crise, order=c(1,1,0), seasonal=c(1,1,0))
```

```
mod3 <- Arima(dados_pos_crise, order=c(1,1,1), seasonal=c(0,1,1))
```

```
AIC(mod1,mod2,mod3)
```

```
BIC(mod1,mod2,mod3)
```

```
##### Verificação do Modelo Ajustado
```

```
## Teste de Estabilidade
```

```
autoplot(mod1)
```

```
## Teste de Autocorrelação
```

```
checkresiduals(mod1)
```

```
## Teste de Normalidade
```

```
shapiro.test(residuals(mod1))
```

```
qqnorm(residuals(mod1)); qqline(residuals(mod1), col="red")
```

```
## Teste de Heterodasticidade
```

```
plot(residuals(mod1)^2, main="Variância dos Resíduos (Squared Residuals)")
```

```
##### Previsão
```

```
treino <- window(dados_pos_crise, end = c(2024, 12))
```

```
real_2025 <- window(dados_pos_crise, start = c(2025, 1))
```

```
mod_treino <- Arima(treino, order=c(1,1,0), seasonal=c(1,1,0))
```

```
previsao_expost <- forecast(mod_treino, h = length(real_2025))
```

```
autoplot(previsao_expost) +
```

```
  autolayer(real_2025, series = "Consumo Real", size = 1) +
```

```
  scale_color_manual(values = c("Forecast" = "blue", "Consumo Real" = "red"),
```



```

        breaks = c("Forecast", "Consumo Real")) +
coord_cartesian(xlim = c(2023.5, 2026.3)) +
theme_minimal() +
labs(title = "Validação Ex-Post: Previsto vs Real",
      x = "Ano",
      y = "Consumo",
      colour = "Referência") +
theme(legend.position = "bottom")

previstos <- as.numeric(previsao_expost$mean)
observados <- as.numeric(real_2025)

datas <- as.yearmon(time(real_2025))

tabela_final <- data.frame(
  Mes_Ano = format(datas, "%b/%y"),
  Real = round(observados, 2),
  Previsto = round(previstos, 2),
  Erro_Abs = round(observados - previstos, 2),
  Erro_Pct = round(abs((observados - previstos) / observados) * 100, 2)
)
print(tabela_final)

##### Previsao Ex-Ante

mod_final <- Arima(dados_pos_crise, order=c(0,1,1), seasonal=c(0,1,1))

previsao_2026 <- forecast(mod_final, h = 12)

autoplot(previsao_2026) +
coord_cartesian(xlim = c(2024, 2027.2)) +

```

```
theme_minimal() +  
labs(x = "Ano",  
     y = "Consumo (Milhões de MWh)") +  
theme(plot.title = element_text(face = "bold"))
```

```
datas_futuras <- as.yearmon(time(previsao_2026$mean))
```

```
tabela_previsao <- data.frame(  
  Mes_Ano = format(datas_futuras, "%b/%y"),  
  Previsao_Media = round(as.numeric(previsao_2026$mean), 2),  
  Limite_Inferior_95 = round(as.numeric(previsao_2026$lower[,2]), 2),  
  Limite_Superior_95 = round(as.numeric(previsao_2026$upper[,2]), 2)  
)
```

```
print(tabela_previsao)
```

```
##### Acurácia Ex-Poste
```

```
accuracy(mod1)
```

```
acuracia_teste <- accuracy(previsao_expost, real_2025)  
print(acuracia_teste)
```

```
##### Acurácia Ex-Ante
```

```
accuracy(mod_final)
```